

WSI – Raport z ćwiczenia 3.

Temat: Regresja i klasyfikacja

Autor: Kacper Chabowski 319025

1. Wprowadzenie

Celem ćwiczenia było zaimplementowanie drzew decyzyjnych przy użyciu algorytmu ID3 z ograniczeniem maksymalnej głębokości drzewa. Przy ich pomocy należało przeprowadzić badanie jakości stworzonych klasyfikatorów na zbiorze Cardio Vascular Disease Detection. Zadaniem było odnalezienie wartości maksymalnej głębokości drzewa, która da najlepszy wynik.

2. Założenia projektu

Dane wczytywane zostają z pliku .csv. Część atrybutów w zbiorze należy poddać dyskretyzacji poprzez zdefiniowanie dla nich odpowiednich zakresów i oznaczenie odpowiednia etykieta. Atrybuty te oraz ich podział to:

- Wiek (age) ==> [<40, 40-50, 50-60, 60+]
- Waga (weight) ==> [light, avg, heavy, very_heavy]
- Wzrost (height) ==> [short, avg, tall, very_tall]
- Ciśnienie skurczowe (ap_hi) ==> [norm, elevated, high]
- Ciśnienie rozkurczowe (ap_lo) ==> [norm, elevated, high]

Zaktualizowane dane przygotowujemy do wykorzystania w algorytmie. Otrzymujemy dwa zbiory danych:


X – zbiór danych bez atrybutu klasy,

y – zbiór danych przechowujący atrybut klasy dla każdej próbki z X.


Zbiory danych podzielono na zbiory trenujący, walidacyjny oraz testowy w proporcjach 60-20-20%.

W celu odnalezienia optymalnej głębokości uruchomiono algorytm dla wszystkich możliwych głębokości dla naszego zbioru danych.

3. Wyniki eksperymentu



- **Zbiór treningowy:** Wraz ze wzrostem głębokości drzewa (od 1 do 11), dokładność na zbiorze treningowym (niebieska linia przerywana) rośnie monotonicznie, zaczynając od ok. 71% i osiągając prawie 77% przy głębokości 11. Świadczy to o coraz lepszym dopasowaniu modelu do danych uczących.
- **Zbiór walidacyjny:** Dokładność na zbiorze walidacyjnym (pomarańczowa linia ciągła) początkowo rośnie, osiągając **maksimum dla głębokości 4 (Accuracy $\approx$ 72.2%)**.
- Po przekroczeniu głębokości 4, skuteczność walidacyjna zaczyna drastycznie spadać, osiągając przy głębokości 11 wynik poniżej 69.5%, mimo że wynik na zbiorze treningowym jest wtedy najwyższy.



Dla odnalezionej optymalnej głębokości $depth = 4$, wykorzystano zbiory walidacyjne i trenujące do trenowania modelu. Następnie przystąpiono do testowania modelu na zbiorze testującym. Wyniki przedstawiono jako macierz pomyłek. Do jej wizualizacji użyto mapy cieplnej. Macierz pomyłek składa się z czterech zbiorów danych:

- **True Negative (TN):** 5237 – Prawidłowo sklasyfikowani pacjenci zdrowi.
- **True Positive (TP):** 4803 – Prawidłowo wykryte przypadki choroby.
- **False Positive (FP):** 1698 – Osoby zdrowe błędnie uznane za chore (błąd I rodzaju).
- **False Negative (FN):** 2123 – Osoby chore błędnie uznane za zdrowe (błąd II rodzaju).

Sumaryczna dokładność na zbiorze testowym jest opisana wzorem:

$$Accuracy = \frac{TN + TP}{TN + TP + FP + FN} = \frac{5237 + 4803}{5237 + 4803 + 1698 + 2123} \approx 0,7243$$

4. Wnioski

1. Do zastosowań praktycznych najlepiej wypadła głębokość równa 4. Jej dokładność wyniosła około 72,4% co jest wynikiem zadowalającym biorąc pod uwagę implementację czystego algorytmu ID3 bez zastępowania poddrzewa liściem o najczęstszej wartości.

2. Na wykresie dokładności od głębokości zauważamy pojawiający się overfitting wraz z inkrementacją parametru depth. Spadek dokładności dla zbioru danych walidujących, a jednocześnie wzrost dokładności na zbiorze treningowym jest charakterystyczną cechą overfittingu.
3. Istotnym jest odpowiednia dyskretyzacja danych ciągłych. Kiedy wydzielimy zbyt mało kwantyli wyniki mogą być oszukane. Dlatego warto wybrać przedziały odpowiednie dla danego zestawu danych. W moim przypadku dobrym przykładem jest podzielenie ciśnienia rozkurczowego na 3 przedziały określone etykietami norm, elevated, high i przypisanie im znanych wartości takich jak optymalne ciśnienie 120 mmHg oraz górna granica, po przekroczeniu, której można zdiagnozować nadciśnienie.