

WSI – Raport z ćwiczenia 4.

Temat: Zagadnienie przeszukiwania i podstawowe podejścia do niego

Autor: Kacper Chabowski 319025

1. Wprowadzenie

Celem ćwiczenia było zaimplementowanie algorytmu gradientu prostego oraz zastosowanie go do znalezienia minimum funkcji Ackleya. Algorytm należało przetestować dla funkcji Ackleya jedno oraz dwu wymiarowej. Kolejnym zadaniem było zbadanie wpływu rozmiaru kroku alfa na działanie algorytmu.

2. Założenia projektu

Dla zadanych wymiarów funkcja Ackleya przyjmuje postacie:

- Dla 1-D

$$f(x) = -20 \exp(-0.2\sqrt{x^2}) - \exp(\cos(2\pi x)) + 20 + e$$

- Dla 2-D

$$f(x) = -20 \exp\left(-0.2 \sqrt{\frac{x^2 + y^2}{2}}\right) - \exp\left(\frac{\cos(2\pi x) + \cos(2\pi y)}{2}\right) + 20 + e$$

Do prawidłowego zaimplementowania algorytmu należało zdefiniować wzór na gradient funkcji Ackleya. Problem ten rozwiązano poprzez podzielenie ogólnego wzoru Ackleya na 2 części, wyliczenie dla obu ich pochodnej, a następnie złożeniu całego wyrażenia w całość. Implementacje stworzono tak, aby działała dla dowolnej funkcji $\mathbf{R}^n \rightarrow \mathbf{R}$.


Badanie przeprowadzono dla stałych:

NAZWA	WARTOŚĆ	OPIS
START_POINT_1D	[3.0]	Punkt startowy dla 1D
START_POINT_2D	[4.0, -3.0]	Punkt startowy dla 2D
MAX_ITERATIONS	1000	Liczba iteracji
LEARNING_RATE	[0.01, 0.05, 0.1, 0.5]	Wartość kroku
SHIFT	1e-15	Przesunięcie dla optimum

3. Wyniki eksperymentu

Wyniki eksperymentu przedstawiono na trzech rodzajach wykresów. Pierwsze badanie polegało na sprawdzeniu dla obu zadanych wymiarów zbieżności algorytmu. Aby wyniki

poprawnie przedstawić na jednym wykresie dla danego wymiaru należało użyć skali logarytmicznej. Wykres ten miał za zadanie pokazać jak poradzi sobie z odnalezieniem optimum dla zadanej wartości LR [LEARNING_RATE].




Rys. 1. Wykres zbieżności algorytmu dla 1D oraz 2D

Dane przedstawiono w pierwszych 100 iteracjach, aby wykres był bardziej czytelny. Zauważamy, iż algorytm dla różnych wymiarów posiada różne optymalne wartości LR. W przypadku 1D, najlepsze wyniki otrzymano przy $LR = 0.05$. Warto zwrócić również uwagę na $LR=0.1$, dla którego podobnie jak dla wartości poprzedniej pozwala algorytmowi na „schodzenie” do optimum, co jest zjawiskiem pożądanym, jednak dla tej wartości nigdy nie otrzymano równie dobrych wyników. Od razu uwagę przyciąga przebieg algorytmu dla $LR=0.01$, gdyż jest on całkowicie płaski. Oznacza to, że algorytm wpadł do najbliższego optimum lokalnego i z powodu, zbyt niskiego kroku nie jest w stanie się z niego wydostać. Przykładem zbyt wysokiej wartości kroku jest zaś $LR=0.5$. Pomimo tego, że kilkakrotnie znajdował się blisko optimum globalnego, algorytm przeskakiwał do optimów lokalnych, gdyż miał on po prostu za duży krok, co sprawiło, że działał chaotycznie.

Dla wymiaru 2D algorytm $LR=0.5$ również okazało się zbyt wielkim krokiem. Zauważamy, że wartości nie dążą do wartości optimum lokalnego. Przesadzona wartość LR skutkuje przestrzałem i brakiem jasno określonej tendencji do krążenia wokół optimum lokalnego. Po drugiej stronie tego problemu są wartości $LR = \{0.01, 0.05\}$. Okazują się one zbyt małymi, aby uciec z najbliższego optimum lokalnego od punktu startowego. Złotym środkiem tym razem jest $LR=0.1$. Prawidłowo schodzi w okolice optimum lokalnego i oscyluje wokół niego. Taka oscylacja jest wynikiem satysfakcjonującym dla zagadnienia przeszukiwania metodą gradientu prostego dla funkcji Ackleya.


OKNO 2: Trajektorie w 1D



Rys. 2. Wykres trajektorii w 1D

Aby w pełni zwizualizować, który z wartości LR jest optymalny dla funkcji Ackleya w 1D przedstawiono zestawienie czterech wykresów dla algorytmu o zadanym LR. Pokazano na nich jakie punkty zostały odwiedzone podczas przeszukiwania. Potwierdził się wniosek do rys. 1. mówiący o najlepszych wynikach dla $LR = 0.05$, a zaraz po nim wyniki działania algorytmu z $LR = 0.1$. Wyraźnym jest także, że złe dobranie wartości $LR=0.01$, które nie daje szans algorytmowi na ucieknienie z optimum lokalnego oraz ogromny rozstrzał po funkcji dla $LR=0.5$, który niekontrolowanie przeszukuje optimum w pełnej dziedzinie funkcji. Oś pionowa opisuje wartości y, zaś oś pozioma opisuje wartości x.

OKNO 3: Trajektorie w 2D



Rys. 3. Wykres trajektorii w 2D

Analogicznie przedstawiono wykres przeszukiwania funkcji trajektorii w 2D. Dzięki odpowiednio dobranym kolorom dobrze widać optima lokalne, które charakteryzują się ciemniejszymi kolorami. Punkt startowy oznaczono białą kropką z czarną obwódką, zaś optimum globalne jako żółta gwiazdka. Kolorem czerwonym oznaczono odwiedzone punkty przeszukiwań. Podobnie jak w 1D zauważamy, że $LR=0.01$ jest zbyt małe aby uciec z minimum lokalnego leżącego najbliżej punktu startowego. Jednak w odróżnieniu do mniejszego wymiaru wartość $LR=0.05$ jest niewystarczająca. Algorytm nie może uciec z lokalnego minimum. Jedyne co to oscyluje wokół niego. Optymalnym krokiem w tym przypadku było $LR=0.1$. Dzięki niemy algorytm jest w stanie przebić się przez optima lokalne i znaleźć się w okolicy optimum globalnego. Następnie rozpoczyna przeszukiwanie tej okolicy co skutkuje oscylacją przy najlepszym wyniku co jak już wspomniano dla tego problemu jest wynikiem satysfakcjonującym. $LR=0.5$ ponownie okazuje się być zbyt duże przez co algorytm chaotycznie przeszukuje funkcję w całej dziedzinie i choć trafia w okolice minimum globalnego, nie można tego uznać jako akceptowalne.

Wnioski:

- Zagadnienie przeszukiwania wiąże się z koniecznością zbadania różnych wartości LR i odnalezienia takiego, który poskutkuje najlepszymi wynikami podczas testów
- Dla różnych wymiarów przeszukiwania, optymalna wartość LR dla tej samej funkcji może się różnić

- Odnalezienie optimum nie zawsze oznacza poprawne dobranie LR. Może się zdarzyć, że odnalezienie tego punktu było szczęśliwym trafem, który jest skutkiem zbyt wysokiego LR
- W testach ważnym jest, aby odpowiednio obrać punkt startowy, tak, aby testy mogły ukazać realne możliwości zbyt niskiego i zbyt wysokiego LR. Punkt startowy zbyt blisko optimum lokalnego skutkuje 100% skutecznością w odnajdywaniu go dla małych rozmiarów LR.
- Dobranie odpowiednich LR oraz liczby iteracji pozwala na odnalezienie satysfakcjonujących wyników przy ograniczeniu czasu przeszukiwania.