

WSI – Raport z ćwiczenia 5.

Temat: Sztuczne sieci neuronowe

Autorzy: Karol Zalewski 319128, Kacper Chabowski 319025

1. Wprowadzenie

Celem ćwiczenia było zaimplementowanie perceptronu wielowarstwowego (MLP) oraz wybranego algorytmu optymalizacji gradientowej, z wykorzystaniem metody propagacji wstecznej. Do zadania dołączono plik wsi5-25Z_dataset.csv na podstawie, którego należało wytrenować perceptron wielowarstwowy do klasyfikacji jakości wina na podstawie zawartych w pliku parametrów. Kolumną do przewidywania była kolumna quality.

2. Założenia projektu

Zbiór danych zawierał ustandaryzowane cechy wejściowe (m.in. zawartość alkoholu, pH, kwasowość) oraz cechę wyjściową "quality" przeskalowaną do zakresu 0-5. Dane zostały podzielone na trzy zbiory: trenujący, walidacyjny i testowy w proporcjach 60-20-20%.

W ramach eksperymentów badano wpływ parametrów na zdolność poprawnej predykcji przez sieć. Kluczowe parametry to:

- architektura sieci - testowano różne układy warstw ukrytych (zarówno ilość tych warstw, jak i różne ich szerokości, czyli liczby neuronów w warstwie),
- współczynnik uczenia (learning rate) - dobrano optymalną wartość pozwalającą na stabilną zbieżność (aby uniknąć zbyt wolnego uczenia, ale jednocześnie nie pozwalając na overfitting).


Każda klasa jakości została zamieniona na wektor binarny (one-hot encoding). Dzięki temu sieć posiadała tyle samo neuronów wyjściowych, ile było unikalnych ocen jakości w zbiorze.

W warstwach ukrytych zastosowano funkcję aktywacji ReLU, aby umożliwić sieci naukę nieliniowych zależności i uniknąć problemu zanikającego gradientu. W warstwie wyjściowej wykorzystano funkcję Sigmoid lub Linear i porównano je między sobą. Jako funkcję celu, służącą do obliczania błędu i późniejszej aktualizacji wag w procesie propagacji wstecznej, wykorzystano błąd średniokwadratowy.

3. Wyniki eksperymentu


Na początku zostało sprawdzone, jaki wpływ na wyniki ma zmienianie liczby warstw, a także liczby neuronów w warstwach. Learning rate został przyjęty jako 0.05. Ostatnia warstwa używała funkcji aktywacji Sigmoid, a reszta ReLU.

Test 1: Jedna, słaba warstwa ukryta (8 neuronów):




Skuteczność modelu: 56.96%

Test 2: Jedna, mocna warstwa ukryta (64 neurony):




Skuteczność modelu: 53.43%

Test 3: Dwie, średnie warstwy ukryte (32 i 16 neuronów):




Skuteczność modelu: 53.43%

Następnie Sigmoid został zmieniony na funkcję Linear w celu porównania tych dwóch funkcji aktywacji (test został wykonany dla dwóch warstw 32 i 16):




Sprawdzony został także wpływ zmiany parametru learning_rate na wynik uczenia:

Test 1: Niski learning_rate (0.0001):



Sieć uczy się w tym przypadku znacznie zbyt wolno - stąd praktycznie prosta linia.

Test 2: Wysoki learning_rate (0.5)



Można tutaj zauważyć bardzo niestabilny wykres świadczący o wysokim overfittingu. Mimo to skuteczność modelu osiągnęła w tym przypadku 59.31%.

4. Wnioski

Zwiększenie liczby neuronów w warstwie bądź liczby warstw nie miało zbyt dużego wpływu na skuteczność modelu. Wyniki wskazują na to, że mała pojedyncza warstwa ukryta okazała się najbardziej efektywna dla tego zbioru danych, co sugeruje, że zależności między parametrami wina a jego jakością nie wymagają bardzo głębokiej architektury.

Przy bardzo niskim współczynniku uczenia (0.0001) sieć praktycznie nie robiła postępów. Wykres MSE jest linią prostą, co pokazuje, że kroki optymalizacji były zbyt małe, by w założonej liczbie 500 epok dotrzeć do minimum funkcji straty. Przy wysokim współczynniku (0.5) wykres staje się bardzo poszarpany i niestabilny. Wyraźny rozstęp między malejącym błędem treningowym a rosnącym błędem walidacyjnym świadczy o tym, że model zaczął uczyć się danych na pamięć, zamiast szukać ogólnych reguł.

Zastosowanie funkcji Linear zamiast Sigmoid w warstwie wyjściowej nie wpłynęło znacząco na skuteczność końcową, jednak funkcja liniowa wydawała się być bardziej podatna na fluktuacje błędu w późniejszych etapach uczenia.

Model we wszystkich testach wykazał największą skuteczność w klasyfikowaniu ocen klasy 2 oraz 3, co prawdopodobnie wynika z największej ilości próbek dla tych klas. Dla mniej licznych klas sieć myliła się jednak o maksymalnie jedną czy dwie klasy, co świadczy o wychwytywaniu przez model pewnych trendów.