

WSI – Raport z ćwiczenia 6.

Temat: Uczenie się ze wzmocnieniem

Autor: Kacper Chabowski 319025

1. Wprowadzenie

Celem ćwiczenia było zaimplementowanie implementacja algorytmu Q-learning z epizodami oraz ϵ -zachłanną strategią wyboru akcji. Gotową implementację należało wykorzystać do wytrenowania agenta rozwiązującego problem Four Rooms (zgodny ze źródłem: <https://minigrid.farama.org/environments/minigrid/FourRoomsEnv/>), który dostępny jest w pakiecie minigrid.

2. Założenia projektu

Model decyzyjny

Problem modelowany jest jako Proces Decyzyjny Markowa (MDP), gdzie w każdym kroku czasowym t agent obserwuje stan s_t , podejmuje akcję a_t , otrzymuje nagrodę r_t i przechodzi do stanu s_{t+1} .

Reprezentacja stanu

Stan zdefiniowano jako krotkę zawierającą pozycję agenta oraz jego kierunek: (x, y, direction).

Strategia wyboru akcji

Zastosowano strategię ϵ -zachłanną. Z prawdopodobieństwem $1 - \epsilon$ wybierana jest akcja o najwyższej wartości funkcji Q, a z prawdopodobieństwem ϵ akcja losowa, co pozwala na eksplorację środowiska.

Funkcja nagrody

W kodzie zastosowano modyfikację nagrody. Oprócz standardowej nagrody za osiągnięcie celu, agent otrzymuje karę -0.01 za każdy krok, co ma na celu zmotywowanie go do znalezienia najkrótszej ścieżki.

Kluczowym elementem jest funkcja wartości akcji $Q(s,a)$, która jest aktualizowana iteracyjnie zgodnie ze wzorem:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \beta \left(r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right)$$

Wzór z prezentacji wsi_2022Z_6-pres

Gdzie badane parametry oznaczają:


1. **β (Beta / Learning Rate):** Współczynnik szybkości uczenia. Określa, jak mocno nowa informacja (błąd predykcji) wpływa na dotychczasową wartość w tablicy Q.
2. **γ (Gamma / Discount Factor):** Współczynnik dyskontowania $\gamma \in (0, 1)$. Określa wagę przyszłych nagród – im niższa wartość, tym bardziej agent skupia się na nagrodach natychmiastowych; im wyższa, tym bardziej uwzględnia długofalowe korzyści.
3. **ϵ (Epsilon):** Parametr eksploracji. Określa prawdopodobieństwo wyboru losowej akcji zamiast optymalnej, co zapobiega utknięciu w lokalnych maksimach na wczesnym etapie uczenia.

3. Wyniki eksperymentu

Przeprowadzono trzy eksperymenty, w każdym badając wpływ jednego parametru przy ustalonych wartościach pozostałych. Wyniki przedstawiono na wykresach obrazujących średnią kroczącą nagród (Rolling Average) w zależności od liczby epizodów.

3.1 Wpływ parametru Beta (Szybkość uczenia)

Badanie przeprowadzono dla wartości $\beta \in \{0.1, 0.3, 0.7, 0.9\}$ przy stałych $\gamma = 0.9$ i $\epsilon = 0.1$.




Na wykresie widać wyraźną korelację między wartością β a szybkością zbieżności algorytmu.

- Dla $\beta=0.1$ (**krzywa niebieska**): Agent uczy się najwolniej. Poziom nasycenia (maksymalna średnia nagroda) osiągnięty jest dopiero w okolicy 200. epizodu.
- Dla $\beta=0.9$ (**krzywa czerwona**): Proces uczenia jest gwałtowny. Już po około 50 epizodach agent osiąga niemal optymalną politykę i stabilizuje wynik na poziomie 0.9–0.95.
- Wartości pośrednie (0.3 i 0.7) wykazują tendencję wzrostową zgodną z oczekiwaniami.

Podsumowanie: W deterministycznym środowisku *FourRooms* wysoki współczynnik uczenia jest korzystny i znacznie przyspiesza znalezienie optymalnej trasy.

3.2 Wpływ parametru Gamma (Współczynnik dyskontowania)

Badanie przeprowadzono dla wartości $\gamma \in \{0.1, 0.3, 0.7, 0.9\}$ przy stałych $\beta = 0.1$ i $\epsilon = 0.1$.




Parametr ten miał krytyczny wpływ na zdolność agenta do rozwiązania zadania.

- Dla $\gamma=0.1$ (**krzywa niebieska**): Agent radzi sobie bardzo słabo, osiągając średnią nagrodę poniżej 0.4. Ze względu na silne dyskontowanie, nagroda za cel (odległy o wiele kroków) jest "niewidoczna" z punktu startowego, przez co agent błądzi.
- Dla $\gamma=0.9$ (**krzywa czerwona**): Jest to najlepsza konfiguracja. Wysokie dyskontowanie pozwala propagować informację o nagrodzie z celu wstecz przez wiele stanów, co jest niezbędne w labiryncie wielopokojowym. Agent osiąga stabilny, wysoki wynik.

Podsumowanie: W środowiskach o rzadkich nagrodach i długim horyzoncie czasowym (jak labirynt), wysoka wartość γ jest niezbędna.

3.3 Wpływ parametru Epsilon (Eksploracja)

Badanie przeprowadzono dla wartości $\epsilon \in \{0.1, 0.3, 0.7, 0.9\}$ przy stałych $\beta = 0.1$ i $\gamma = 0.9$.



Wykres obrazuje tzw. dylemat eksploracji i eksploatacji.

- Dla $\epsilon = 0.1$ (**krzywa niebieska**): Wyniki są najlepsze. Niska wartość eksploracji pozwala agentowi w 90% przypadków korzystać ze zdobytej wiedzy (eksploatacja), co maksymalizuje sumę nagród.
- Dla $\epsilon = 0.9$ (**krzywa czerwona**): Wyniki są najgorsze (średnia nagroda ok. 0.3). Agent zachowuje się niemal losowo. Mimo że prawdopodobnie "odwiedził" cel i zaktualizował tablicę Q, to podczas ewaluacji (treningu) ciągle wykonuje losowe, nieoptymalne ruchy, co obniża wynik i zwiększa liczbę kroków.

Podsumowanie: Zbyt wysoka wartość ϵ uniemożliwia efektywne wykorzystanie nauczonej polityki, drastycznie obniżając uzyskiwane nagrody.

4. Wnioski

1. **Kluczowa rola dyskontowania (γ):** W problemie *FourRooms*, gdzie osiągnięcie celu wymaga wykonania wielu kroków, niska wartość γ (np. 0.1) uniemożliwia skuteczne nauczenie się drogi. Agent staje się "krótkowzroczny". Aby rozwiązać zadanie nawigacji, konieczne jest zastosowanie γ bliskiego 1 (np. 0.9).
2. **Szybkość uczenia (β):** W tym konkretnym, statycznym środowisku, wyższa wartość β (0.9) pozwoliła na znacznie szybsze zbiegnięcie się algorytmu do rozwiązania optymalnego niż wartości niższe. Nie zaobserwowano

negatywnego wpływu oscylacji, który mógłby wystąpić w środowiskach losowych.

3. **Balans eksploracji (ϵ):** Najlepsze wyniki uzyskano dla najniższej badanej wartości $\epsilon=0.1$. Choć eksploracja jest konieczna do odkrycia celu, jej nadmiar (np. $\epsilon=0.7$ lub 0.9) jest destrukcyjny dla całkowitej nagrody, ponieważ agent zbyt często ignoruje swoją wiedzę.