

WSI – Raport z ćwiczenia 7.

Temat: Modele bayesowskie

Autor: Kacper Chabowski 319025

1. Wprowadzenie

Celem ćwiczenia była implementacja algorytmu naiwnego klasyfikatora Bayesa. Gotową implementację należało wykorzystać do stworzenia i zbadania jakości klasyfikatorów dla zbioru danych SMS Spam Collection Dataset. Zbiór ten pobrano ze źródła: <https://www.kaggle.com/datasets/uciml/sms-spam-collection-dataset>. Jako klasę przyjęto pole v1 (class).

2. Założenia projektu

W ramach realizacji zadania przyjęto następujące założenia dotyczące struktury danych oraz działania algorytmu:

- **Struktura danych:** Zbiór danych posiada atrybut decyzyjny class, który przyjmuje jedną z dwóch wartości: **SPAM** (niechciane wiadomości) oraz **HAM** (wiadomości użyteczne).
- **Ogólność implementacji:** Zgodnie z wymaganiami, algorytm został zaimplementowany w sposób ogólny, umożliwiający obsługę dowolnego zbioru danych o atrybutach dyskretnych. Implementacja nie zakłada na sztywno binarności cech, lecz dynamicznie identyfikuje możliwe wartości atrybutów ze zbioru treningowego.
- **Reprezentacja tekstu:** Dane tekstowe zostały przetworzone na wektory cech metodą "Bag of Words" (unigramy). Dla każdej wiadomości atrybutami są wystąpienia słów ze słownika najczęstszych wyrazów. Traktujemy je jako zmienne dyskretne.
- **Model Probabilistyczny:** Klasyfikator opiera się na twierdzeniu Bayesa z "naiwnym" założeniem o wzajemnej niezależności cech (słów) pod warunkiem klasy. Klasa C dla próbki x jest wybierana zgodnie z zasadą maksymalizacji prawdopodobieństwa a posteriori (MAP):

$$\operatorname{argmax}_C P(C) \prod_i P(x_i|C)$$

, gdzie:

- $P(C)$ to prawdopodobieństwo a priori klasy (częstość występowania w zbiorze treningowym).


- $P(x_i|C)$ to prawdopodobieństwo warunkowe wystąpienia wartości atrybutu i w klasie C .
- **Stabilność numeryczna:** Aby uniknąć problemów z niedomiarem arytmetycznym (ang. *underflow*) przy mnożeniu wielu małych prawdopodobieństw, w implementacji zastosowano sumowanie logarytmów prawdopodobieństw zamiast ich iloczynu.
- **Wygładzanie Laplace’a:** Do estymacji prawdopodobieństw $P(x_i|C)$ dodano stałą (wygładzanie), aby zapobiec zerowaniu się prawdopodobieństwa całego wektora w przypadku napotkania w zbiorze testowym słowa niewystępującego w zbiorze treningowym.
- **Walidacja:** Do oceny jakości modelu wykorzystano metodę **k-krotnej walidacji krzyżowej** (dla $k=5$). Zbiór podzielono na 5 części, a ostateczny wynik stanowi średnią z 5 iteracji.
- **Przygotowanie danych:** Nadano stałe ziarno = 42. Przed podziałem na 5 równych części, pomieszano dane, na wypadek jeśli plik wejściowy był posortowany i początkowe wiersze stanowiły by sam SPAM a końcowe sam HAM.

3. Wyniki eksperymentu

Badanie przeprowadzono na pełnym zbiorze 5572 wiadomości SMS. Wyniki dokładności (ang. *Accuracy*) uzyskane w poszczególnych iteracjach 5-krotnej walidacji krzyżowej prezentują się następująco:


Iteracja	Dokładność
1	98.11%
2	98.29%
3	98.20%
4	98.29%
5	97.85%

Średnia dokładność z 5-ciu iteracji jest równa 98.15%.



RYS.1. Analiza macierzy pomyłek (zsumowanej ze wszystkich iteracji)

- Model osiąga bardzo wysoką skuteczność w identyfikacji klasy **HAM** (ponad 99% poprawnych klasyfikacji).
- Najczęstszym rodzajem błędu jest *False Negative* (zaklasyfikowanie spamu jako bezpiecznej wiadomości), co w kontekście filtrowania wiadomości jest błędem mniej krytycznym niż utrata ważnej korespondencji (*False Positive*).



RYS.2. Analiza wpływu rozmiaru słownika na jakość klasyfikacji

Dodatkowo przeprowadzono badanie mające na celu sprawdzenie, jak liczba uwzględnionych cech (najpopularniejszych słów w słowniku) wpływa na skuteczność modelu. Przetestowano warianty dla 50, 100, 200, 500 oraz 1000 słów.

4. Wnioski

1. Skuteczność metody: Mimo przyjęcia upraszczającego ("naiwnego") założenia o niezależności występowania słów, klasyfikator Bayesa okazał się bardzo skuteczny w zadaniu detekcji spamu, osiągając średnią dokładność na poziomie blisko 97%.
2. Stabilność: Niewielkie odchylenia wyników między poszczególnymi iteracjami walidacji krzyżowej (różnica poniżej 1 punkt procentowy) świadczą o tym, że model jest stabilny i dobrze generalizuje wiedzę na nowe dane.
3. Implementacja ogólna: Zastosowanie podejścia opartego na słownikach wartości atrybutów pozwoliło stworzyć uniwersalny klasyfikator dla danych dyskretnych, spełniając tym samym wymóg ogólności implementacji.

4. Wydajność: Prosta struktura matematyczna algorytmu pozwoliła na szybkie trenowanie i klasyfikację nawet przy dużej liczbie atrybutów (słów), co jest istotną zaletą metod bayesowskich w przetwarzaniu tekstu.
5. Już przy uwzględnieniu zaledwie **50 najczęstszych słów**, model osiąga bardzo wysoką dokładność (~94%), co sugeruje, że w zbiorze istnieje wąska grupa słów silnie skorelowanych ze spamem.
6. Zwiększenie słownika z 50 do 100 słów przynosi zauważalny skok jakości.
7. Dalsze zwiększanie liczby cech (powyżej 500) przynosi coraz mniejsze przyrosty dokładności. Oznacza to, że większość informacji niezbędnej do klasyfikacji zawarta jest w kilkuset najpopularniejszych słowach, a dodawanie rzadszych słów ma marginalny wpływ na wynik.